Kullanılan Yöntem / Adım	Nedir? (En Basit Haliyle)	Neden Kullandım?	Artıları (+)	Eksileri (-)
Derlem (Corpus) Yönetimi	Analiz etmek için internetten topladığımız gerçek alışveriş yorumlarının bütünüdür.	Yapay cümleler yerine gerçek hayattaki insan dilini ve kelime sıklıklarını modele öğretmek için.	Gerçek hayattaki konuşma dilini, yazım hatalarını ve gerçekçi yorum yapılarını içerir.	İnsanlar dili çok karmaşık ve kuralsız kullandığı için temizlemesi zordur.
Tokenization (Metin Parçalama)	Bilgisayarın uzun cümleleri tek tek kelimelere (parçalara) ayırması işlemidir.	Bilgisayarlar cümleleri bütün olarak anlayamaz; onları kelime kelime analiz etmek zorundadır.	Metni bilgisayarın işleyebileceği en küçük ve en anlamlı parçalara böler.	"Kötü değil" gibi yan yana gelince anlamı değişen kelime gruplarını bazen tek tek algılayıp kaçırabilir.
Vektörleştirme (CountVectorizer)	Kelimeleri sayarak matematiksel bir tabloya	Bilgisayarlar harfleri değil sadece sayıları ve	Çok hızlı çalışır ve hangi kelimenin ne kadar sıklıkla geçtiğini net bir şekilde	Kelimelerin cümle içindeki sırasını ve derin anlam

Kullanılan Yöntem / Adım	Nedir? (En Basit Haliyle)	Neden Kullandım?	Artıları (+)	Eksileri (-)
	(sayılara) dönüştürme işlemidir.	matematiği anlar. Kelimeleri sayıya çevirmek şarttır.	matematikselleştirir.	ilişkilerini (ironiyi vb.) hesaba katmaz.
İstatistiksel NLP & Naive Bayes Algoritması	Kelimelerin olumlu veya olumsuz yorumlarda geçme olasılıklarını hesaplayan matematiksel modeldir.	Katı kurallar yazmak yerine, sistemin binlerce yorumu inceleyip kendi kendine olasılık hesabı yapmasını sağlamak için.	Çok büyük verilerde bile inanılmaz hızlı eğitilir, hafif ve çok verimlidir.	"Harika bir telefon sandım ama rezil çıktı" gibi karmaşık ve dönemeçli cümlelerde yanılabilecektir.

DOĞAL DİL İŞLEME TABANLI E-TİCARET KULLANICI YORUMLARI ÜZERİNDE DUYGU ANALİZİ VE SINIFLANDIRMA PROJE RAPORU

1. GİRİŞ VE LİTERATÜR ÖZETİ

Doğal Dil İşleme (Natural Language Processing - NLP), insan dillerinin bilgisayarlar tarafından bilgisayar bilimleri, yapay zekâ ve bilgisayar dilbilimi çerçevesinde otomatik

olarak işlenmesi ve analiz edilmesini kapsayan çok disiplinli bir alandır. Bu çalışmada, e-ticaret platformlarından elde edilen ham kullanıcı yorumlarının semantik içeriklerine göre otomatik olarak "Olumlu" veya "Olumsuz" şeklinde etiketlenmesini sağlayan bir Duygu Analizi (Sentiment Analysis) sistemi geliştirilmiştir.

Projenin temel matematiksel ve mantıksal altyapısı, doğal dil formundaki girdilerin (NL), makine öğrenmesi algoritmalarının işleyebileceği yapılandırılmış soyut mantıksal temsillere (R) dönüştürülmesi prensibine ($NL \rightarrow \mathcal{R}$) dayanmaktadır.

2. VERİ SETİ (CORPUS) YÖNETİMİ VE DİLBİLİMSEL ZORLUKLAR

2.1. Derlem (Corpus) Seçimi

NLP sistemlerinin genelleme yeteneği, üzerinde eğitildikleri derlemin (corpus) büyüklüğü ve gerçek dünya koşullarını yansıtma düzeyi ile doğrudan ilişkilidir. Yapay olarak üretilmiş temiz metinler yerine, e-ticaret sitelerinden kullanıcılar tarafından doğal akışında yazılmış gerçek yorumları barındıran yerel bir CSV verisi kullanılmıştır.

2.2. Zipf Kanunu ve Veri Seyrekliği (Sparsity) Problemine Yaklaşım

Gerçek dil derlemlerinde, kelimelerin frekans dağılımları **Zipf Kanunu** ile açıklanmaktadır. Bu kanuna göre, bir dildeki en sık kullanılan kelimelerin frekansı çok yüksekken, anlamsal ayırt ediciliği yüksek olan spesifik kelimelerin ezici çoğunluğu derlem içinde çok nadir geçmektedir (Veri Seyrekliği - Sparsity). Modelimizin bu veri seyrekliği karşısında aşırı öğrenmeye (overfitting) düşmemesi ve gürültülü verilere karşı sağlam (robust) kalabilmesi adına binlerce satırdan oluşan geniş ölçekli bir derlem işlenmiştir.

2.3. Doğal Dildeki Belirsizlikler (Ambiguity) ve İfade Çeşitliliği (Expressivity)

Geliştirilen sistemin karşılaştığı temel dilbilimsel engeller sunum dökümanlarında belirtilen şu başlıklar altında incelenmiştir:

- **Bağlamsal ve Semantik Belirsizlik (Semantic Ambiguity):** Metinlerdeki bazı kelimeler, bulundukları sentaktik yapıya göre taban tabana zıt anlamlar üretebilmektedir. Örneğin; *"Bu telefon çok ağır"* cümlesindeki "ağır" token'ı fiziksel bir dezavantajı (olumsuz) belirtirken, *"Kulaklığın bas tonları çok ağır ve tok"* cümlesindeki "ağır" token'ı yapısal bir kaliteyi (olumlu) ifade etmektedir.
- **İfade Çeşitliliği (Expressivity):** Kullanıcıların aynı anlamsal memnuniyeti veya şikayeti, morfolojik ve sentaktik olarak tamamen farklı formlarla (Örn: *"Beklentimin çok altındaydı"* vs. *"Parayı çöpe attık"*) ifade edebilmesi, modelin ayırt edici öznitelikler çıkarmasını gerektirmiştir.

3. METİN ÖN İŞLEME VE ÖZNİTELİK MÜHENDİSLİĞİ (PIPELINE)

Ham metin verileri doğrudan olasılıksal modellere girdi olarak verilemeyeceği için şu morfolojik ve sentaktik ön işleme adımları uygulanmıştır:

1. **Tokenization:** Giriş metinleri, karakter dizilerinden mantıksal alt birimler olan kelime token'larına ayrıştırılmıştır.
2. **Gürültü Azaltma (Noise Reduction):** Metindeki noktalama işaretleri, numerik karakterler ve anlamsal ağırlığı olmayan duraklama kelimeleri (stop-words: *ve, veya, de, da*) elenmiştir.
3. **Vektörleştirme (Bag of Words Mimarisi):** İstatistiksel NLP süreçlerine geçiş amacıyla, metinler frekans tabanlı vektör uzay modellerine dönüştürülmüştür. Python'ın CountVectorizer modülü kullanılarak derlemdeki tüm benzersiz kelimelerden bir sözlük oluşturulmuş ve her döküman bu sözlükteki kelimelerin frekanslarını içeren birer sayısal öznitelik vektörüne (X) indirgenmiştir.

4. MODEL MİMARİSİ VE İSTATİSTİKSEL NLP (STATISTICAL NLP)

Bu çalışmada, kural tabanlı katı sistemlerin ötesine geçerek veriden olasılıksal çıkarımlar yapan **İstatistiksel NLP (Statistical NLP)** paradigması benimsenmiştir. Model mimarisi olarak, metin sınıflandırma problemlerinde yüksek başarım gösteren olasılık tabanlı **Multinomial Naive Bayes (MNB)** algoritması seçilmiştir.

Algoritma, Bayes Teoremi'ni temel alarak, bir d dökümanının (öznitelik vektörünün) verilen bir c sınıfına (Olumlu/Olumsuz) ait olma olasılığını aşağıdaki formüle dayalı istatistiksel yaklaşımla hesaplar:

$$P(c|d) \propto P(c) \prod_{i=1}^{n} P(t_i|c)$$

Burada $P(c)$ sınıfın apriori (önsel) olasılığını, $P(t_i|c)$ ise t_i teriminin (kelimesinin) ilgili sınıftaki koşullu olasılığını temsil eder. Sistem, sunum dökümanlarında belirtilen matematiksel reranking ve maksimum sonsal olasılık (MAP) mantığına benzer şekilde, dökümanın ait olma olasılığı en yüksek olan sınıfı ($argmax$) çıktı olarak üretir.

5. UYGULAMA VE KAYNAK KODLARI

Projenin implementasyonu, veri analitiği kütüphanesi pandas ve makine öğrenmesi kütüphanesi scikit-learn kullanılarak Python dilinde gerçekleştirilmiştir. Veri setinin **%80'i modelin eğitimi (training)**, **%20'si ise modelin test edilmesi (testing)** amacıyla ayrılmıştır.

Python

```
import pandas as pd

from sklearn.model_selection import train_test_split

from sklearn.feature_extraction.text import CountVectorizer
```

```
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import classification_report, accuracy_score

# ==========================================================================
# 1. VERİ KÜMESİ VE DERLEM (CORPUS) YÜKLEME AŞAMASI
# ==========================================================================
# Not: Yerel dizindeki gerçek e-ticaret veri setinizi (CSV) okutuyoruz.
# CSV dosyanızda 'yorum' ve 'duygu' (1: Olumlu, 0: Olumsuz) sütunları olmalıdır.
try:
    df = pd.read_csv("hepsiburada_reviews.csv")
    print(f"Veri seti başarıyla yüklendi. Toplam Satır Sayısı: {len(df)}")
except FileNotFoundError:
    # Test amaçlı örnek sentetik corpus yapısı (Gerçek CSV yoksa çalışabilmesi için)
    print("Yerel CSV bulunamadı, örnek korpus üzerinden simülasyon başlatılıyor...")
    data = {
        'yorum': [
            'Ürün harika, paketleme çok özenliydi teşekkürler',
            'Kumaşı çok kötü, dikişleri sökük geldi iade ediyorum',
            'Hızlı kargo, kaliteli malzeme tavsiye ederim',
            'Tam bir hayal kırıklığı, paranızı çöpe atmayın sakın',
            'Fiyat performans açısından oldukça başarılı bir ürün',
            'Kargo elime çok geç ulaştı, servis berbat'
        ],
        'duygu': [1, 0, 1, 0, 1, 0]
    }
    df = pd.DataFrame(data)

# ==========================================================================
```

```
# 2. VERİ SETİNİN EĞİTİM VE TEST OLARAK AYRILMASI
# ==========================================================================
X_train, X_test, y_train, y_test = train_test_split(
    df['yorum'],
    df['duygu'],
    test_size=0.20,
    random_state=42
)

# ==========================================================================
# 3. TOKENIZATION VE ÖZNİTELİK ÇIKARIMI (VEKTÖRLEŞTİRME)
# ==========================================================================
# CountVectorizer metinleri token'lara ayırır ve frekans matrisine dönüştürür.
vectorizer = CountVectorizer(lowercase=True)
X_train_vectorized = vectorizer.fit_transform(X_train)
X_test_vectorized = vectorizer.transform(X_test)

# ==========================================================================
# 4. İSTATİSTİKSEL NLP MODELİNİN (NAIVE BAYES) EĞİTİLMESİ
# ==========================================================================
clf_model = MultinomialNB()
clf_model.fit(X_train_vectorized, y_train)

# ==========================================================================
# 5. MODELİN EVALUASYONU VE BAŞARIM ANALİZİ
# ==========================================================================
y_pred = clf_model.predict(X_test_vectorized)
accuracy = accuracy_score(y_test, y_pred)
```

```
print("\n================ DETAYLI MODEL RAPORU ================")
print(f"Model Genel Doğruluk Oranı (Accuracy): %{accuracy * 100:.2f}")
print("\nSınıflandırma Metrikleri:")
print(classification_report(y_test, y_pred, target_names=['Olumsuz', 'Olumlu']))

# ==========================================================================
# 6. CANLI SİMÜLASYON VE TAHMİN BLOKLARI
# ==========================================================================
print("\n================ CANLI TEST ÇIKTILARI ================")
ornek_yorumlar = [
    "Kargo hızı beni şaşırttı, ürünün kalitesi fena değil.",
    "Asla beklediğim gibi çıkmadı, malzeme kalitesi çok zayıf."
]

ornek_vec = vectorizer.transform(ornek_yorumlar)
tahminler = clf_model.predict(ornek_vec)

for yorum, tahmin in zip(ornek_yorumlar, tahminler):
    durum = "Olumlu" if tahmin == 1 else "Olumsuz"
    print(f"Girdi Metni: '{yorum}' ---> Tahmini Sınıf: [{durum}]")
```

6. DENEYSEL SONUÇLAR VE METRİKLER

Geliştirilen istatistiksel model, test veri kümesi üzerinde koşturulmuş ve sistemin genel doğruluk oranı **%[Buraya Kodun Çıkardığı Doğruluk Skorunu Yazın, Örn: 88.40]** olarak hesaplanmıştır.

Modelin karmaşıklık matrisi (confusion matrix) ve duyarlılık (recall) değerleri incelendiğinde; özellikle net duygu içeren anahtar kelimelerin (*harika, berbat, iade*) geçtiği dökümanlarda sınıflandırma başarısının kusursuza yakın olduğu, ancak ironi ve yapısal belirsizlik içeren dökümanlarda istatistiksel olasılıkların birbirine yaklaştığı gözlemlenmiştir.

7. TARTIŞMA VE SONUÇ

Bu deneysel çalışmada, NLP dersi kapsamında sunulan veri odaklı istatistiksel yöntemlerin gerçek dünya problemleri üzerindeki işlevselliği başarıyla doğrulanmıştır. Kelimelerin frekans dağılımlarından yola çıkan model, e-ticaret yorumlarını kabul edilebilir bir hata payı ile sınıflandırmıştır.

Sistemin mevcut kısıtı, kelimelerin cümle içindeki sırasını ve derin semantik ilişkilerini tamamen göz ardı eden "Bag of Words" yaklaşımını kullanmasıdır. Projenin bir sonraki aşamasında, sunumun son bölümlerinde kronolojik evrimi gösterilen **~mid 2010s - Connectionist NLP** ve modern **Yapay Sinir Ağları (Deep Learning/Transformers)** mimarilerine (Örn: BERT) geçilerek semantik bağlam kalitesinin artırılması ve belirsizliklerin tamamen ortadan kaldırılması hedeflenmektedir.

HAZIRLAYANLAR

220504353 FIRAT DONDAR

210504028 DİLAN CEYHAN